

1 Статистика (Теория)

Проверка статистических гипотез

- X - полученная в эксперименте выборка
- \mathbb{F} - множество априори допустимых распределений X
- $F \in \mathbb{F}$ - истинное распределение X
- Нулевая гипотеза $H : F \in \mathbb{F}_0 \subset \mathbb{F}$
- Альтернатива $H : F \in \mathbb{F} \setminus \mathbb{F}_0$

Определение 1.

Простая гипотеза (или альтернатива) – такая, при которой множество \mathbb{F}_0 (или \mathbb{F}_1) содержит единственный элемент. Иначе гипотеза (или альтернатива) называется сложной.

Если мы предположим, что \mathbb{F} – единственный элемент, то это означает, что F мы сравниваем с единственным элементом. Соответствующая гипотеза полностью определяет распределения вероятностей, с которыми производится работа.

Определение 2.

Статистический критерий – правило, согласно которому, наблюдая X , можно принять решение об отклонении гипотезы H_0 .


Мы никогда не можем ничего подтвердить с помощью статистики, но некоторые факты можно опровергнуть. Можно сказать, что мы принимаем некоторую гипотезу H_0 и оказывается, что данные, полученные в эксперименте, плохо соответствуют этой гипотезе.

Общий принцип - если при справедливости гипотезы H_0 наблюдаемое событие (выборка X) маловероятно, то такую гипотезу следует отклонить.

Определение 3.

Критическая область – множество выборок X , для которых гипотеза H_0 отклоняется.

		Истина	
		Нет	Да
Отклонить?	Нет	Ошибка 2 рода β	Правильное не отклонение
	Да	Правильное отклонение	Ошибка 1 рода α



Ошибка 1 рода – гипотеза отклоняется, а на самом деле она была верна.

Ошибка 2 рода – гипотеза подтверждается, а на самом деле она была не верна.

Линию Г (гамма) необходимо провести таким образом, чтобы минимизировать ошибки α и β .

1. Если всегда отклонять H_0 , то получится $\beta = 0$; $\alpha > 0$

2. Если никогда не отклонять H_0 , то получится $\alpha = 0$; $\beta > 0$

3. Пусть ошибка 1 рода не превышает α , а ошибка 2 рода будет минимальная - критерий Неймана-Пирсона

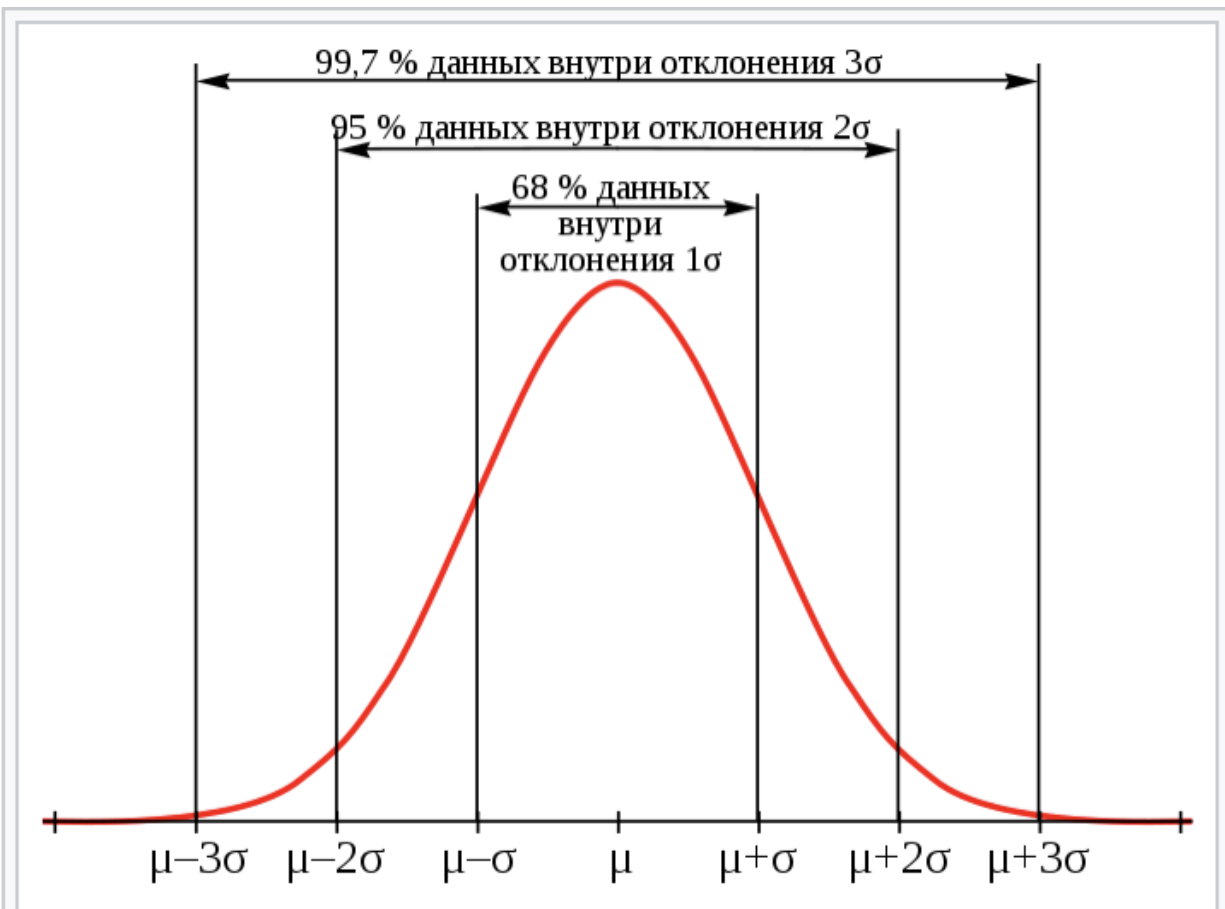
4. Пусть "цена" ошибок 1 и 2 рода будет в среднем минимальная - байесовский критерий

- Если «цена» ошибок неизвестна, но заданы их вероятности – критерий Котельникова (апостериорной плотности распределения)
- Если неизвестны ни «цена», ни вероятность ошибок – критерий максимального правдоподобия

Про нормальное распределение

1. Центральная предельная теорема (ЦПТ):

ЦПТ утверждает, что сумма достаточно большого количества слабо зависимых случайных величин, имеющих примерно одинаковые масштабы (ни одно из слагаемых не доминирует, не вносит в сумму определяющего вклада), имеет распределение, близкое к нормальному. Это объясняет, почему нормальное распределение так широко встречается в реальных данных.



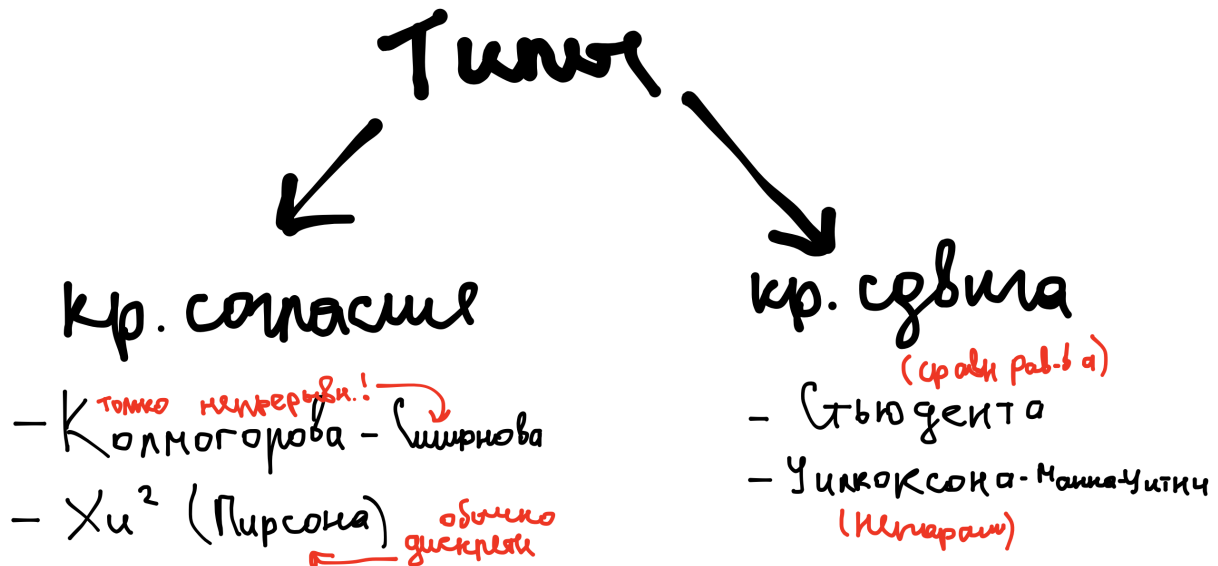
Правило 68-95-99,7.



Для нормального распределения количество значений, отличающихся от среднего на число, меньшее чем одно стандартное отклонение, составляют 68,27 % выборок. В то же время количество значений, отличающиеся от среднего на два стандартных отклонения, составляют 95,45 %, а на три стандартных отклонения — 99,73 %.

Типы статистических критериев

В зависимости от проверяемой *нулевой гипотезы* статистические критерии делятся на группы.



Критерии согласия

Критерии согласия проверяют, согласуется ли заданная выборка с заданным фиксированным распределением, с заданным параметрическим семейством распределений, или с другой выборкой.

Критерии сдвига

Специальный случай двухвыборочных критериев согласия. Проверяется гипотеза сдвига, согласно которой распределения двух выборок имеют одинаковую форму и отличаются только сдвигом на константу.